

Exercice d'application IA

Tout au long nous utiliserons le fichier StudentsPerformance .csv avec comme variable cible le 'writing score'.

0. Préparation des données

1. Analyse non-supervisée

A. Clustering avec K-means

- Appliquez l'algorithme K-Means sur l'ensemble des features du jeu de données.
- Utilisez la méthode du coude en calculant l'inertie intra-cluster pour différentes valeurs de K. Tracez le graphique de l'inertie en fonction de K.
- Sur la base du graphique, déterminez une valeur optimale pour K. Justifiez brièvement votre choix.
- Ré-appliquez K-Means avec le K optimal choisi.

B. Réduction de dimensionnalité et visualisation

- Appliquez l'analyse en composantes principales (PCA) pour réduire la dimensionnalité des features à 2 composantes principales.
- Créez un graphique (scatter plot) des données projetées sur ces 2 composantes.
- Analysez visuellement si les clusters semblent bien séparés dans cet espace réduit.
- Analysez les résultats de la PCA.
- Appliquez t-SNE pour réduire la dimensionnalité à 2 composantes. Jouez avec le paramètre perplexity (essayer au moins deux valeurs).
- Comparez la séparation visuelle obtenue avec t-SNE par rapport à la PCA.

2. Apprentissage supervisé

A. Préparation et sélection des features

- Séparez votre jeu de données en un ensemble d'entraînement (75%) et un ensemble de test (25%).
- Calculez et affichez la matrice de corrélation (heatmap) sur les features de l'ensemble d'entraînement. Y a-t-il des features fortement corrélées qui pourraient être redondantes ?
- Utilisez l'algorithme Boruta (avec un le meilleur RandomForest) pour identifier les features pertinentes pour prédire la variable cible sur le jeu d'entraînement. Quelles features sont sélectionnées comme 'Confirmées' ?
- Créez un nouveau jeu de données d'entraînement et de test ne contenant que les features confirmées par Boruta.

B. Entraînement et évaluation des modèles

- Sur le jeu de données réduit (features sélectionnées par Boruta) :
 - Entraînez un modèle XGBoost. Vous pouvez tester rapidement 2 ou 3 combinaisons simples d'hyperparamètres.
 - Entraînez un Perceptron Multi-Couches (MLP). Testez au moins une architecture simple (e.g., 2 couches cachées avec activation ReLU). N'oubliez pas de standardiser les données pour le MLP.

- Évaluez la performance de XGBoost et MLP sur l'ensemble de test réduit en utilisant des métriques appropriées.
- Quel modèle semble le plus performant sur ce jeu de données réduit ?

3. Combinaison et explicabilité

A. Ingénierie des features via clustering

- Reprenez les assignations de cluster obtenues avec K-Means (avec K optimal) dans la Partie 1.
- Ajoutez ces assignations de cluster comme une nouvelle feature à votre jeu de données d'entraînement complet.
- Entraînez à nouveau votre meilleur modèle de la Partie 2 (XGBoost ou MLP) sur ce jeu de données augmenté (features initiales + feature de cluster encodée).
- Évaluez sa performance sur l'ensemble de test (auquel vous aurez aussi ajouté la feature de cluster dérivé du K-Means appliqué sur tout le dataset initial, puis encodée). L'ajout de l'information de clustering a-t-il amélioré la performance ?

B. Explicabilité du modèle supervisé

- Utilisez les SHAP values pour analyser ce modèle :
 - Générez un summary plot (en bar) SHAP sur l'ensemble de test. Quelles sont les features les plus importantes globalement pour ce modèle ? Comment leur valeur influence-t-elle la prédiction (impact positif/négatif) ?
 - Générez et analysez le summary plot shap classique.
 - Choisissez une instance spécifique de l'ensemble de test et générez un waterfall plot SHAP pour expliquer la prédiction pour cette instance particulière. Interprétez le graphique.
- Utilisez les ICE plots (Individual Conditional Expectation) pour visualiser l'effet des plusieurs importantes (identifiées par SHAP) sur les prédictions du modèle pour chaque instance du jeu de test. Que révèlent ces graphiques sur le comportement du modèle par rapport à ces features ?

C. Conclusion

- L'ajout de la feature des clusters a-t-elle eu un impact sur les résultats du modèle ?